

المدرسة الوطنية للعلوم التطبيقية - بني ملال

ⵜⵉⵎⵙⵙⵓⵜ ⵜⴰⵏⴰⵟⵓⵜ ⵏ ⵜⵙⵏⴰⵡⴰⵏ ⵜⵓⵏⵉⵖⵓⵜ - ⴰⵣⵜ ⵎⵃⵎⴰⵍ

Ecole Nationale des Sciences Appliquées - Béni Mellal

École Nationale des Sciences Appliquées
Filière IACS

Classification et Compréhension Automatique de Documents Éducatifs avec BERT

Projet de Traitement Automatique du Langage Naturel

ADJEVI Kodjo Marius-Ben

ELJARIDA Saad Eddine

ALLADO Kossi Richard

KPADENOU Kossi Roland

Modèle :	DistilBERT-base-uncased (version allégée de BERT)
Dataset :	Sous-ensemble de RACE (5k train, 1k val, 1k test)
Framework :	PyTorch + HuggingFace Transformers
Année :	2025-2026

Résumé

Ce rapport présente le développement et l'évaluation d'un système de compréhension de lecture automatique basé sur les modèles Transformers pré-entraînés de type BERT. L'objectif est de construire un classificateur capable de répondre automatiquement à des questions à choix multiples sur des passages de texte éducatifs issus du dataset RACE. Nous détaillons l'architecture du modèle, le processus de fine-tuning, les résultats obtenus et une analyse approfondie des performances selon différents critères (niveau d'éducation, longueur des passages, types de questions). Les résultats démontrent l'efficacité des modèles pré-entraînés pour cette tâche, tout en identifiant certaines limitations et pistes d'amélioration.

Table des matières

1 Introduction **4**
1.1 Contexte et Objectifs . . . 4
1.2 Motivation . . . 4
1.3 Structure du Rapport . . . 4

2 Description du Dataset **4**
2.1 Présentation de RACE . . . 4
2.2 Caractéristiques du Dataset . . . 5
2.3 Format des Données . . . 5
2.4 Statistiques Descriptives . . . 5
2.4.1 Distribution des Longueurs . . . 5
2.4.2 Distribution des Réponses . . . 6
2.5 Exemples de Données . . . 7
2.5.1 Exemple 1 – Niveau Middle School . . . 7
2.5.2 Exemple 2 – Niveau High School . . . 7

3 Méthodologie **8**
3.1 Architecture du Modèle . . . 8
3.1.1 Choix du Modèle de Base . . . 8
3.1.2 Adaptation pour Multiple Choice . . . 8
3.2 Prétraitement des Données . . . 8
3.2.1 Nettoyage du Texte . . . 8
3.2.2 Tokenisation . . . 9
3.3 Hyperparamètres . . . 9
3.4 Procédure d'Entraînement . . . 9
3.5 Infrastructure . . . 10

4 Résultats **10**
4.1 Performances Globales . . . 10
4.1.1 Évolution par Époque . . . 11
4.1.2 Comparaison avec l'État de l'Art . . . 11
4.2 Courbes d'Apprentissage . . . 11
4.3 Matrice de Confusion . . . 12

5 Analyse et Discussion **13**
5.1 Analyse des Performances . . . 13
5.2 Facteurs influençant les performances . . . 13
5.3 Analyse des erreurs . . . 13
5.4 Limites du modèle . . . 13
5.5 Perspectives . . . 13

6 Conclusion **14**

1 Introduction

1.1 Contexte et Objectifs

La compréhension automatique de la lecture représente l'un des défis majeurs du traitement automatique du langage naturel (NLP). Ce projet vise à développer un système capable d'évaluer automatiquement les réponses à des questions à choix multiples (QCM) basées sur des passages de texte éducatifs.

Les objectifs principaux de ce projet sont les suivants :

- ✓ Encoder efficacement des passages de texte et des questions en utilisant des représentations contextuelles modernes
- ✓ Classifier automatiquement la bonne réponse parmi quatre options proposées
- ✓ Évaluer la capacité du modèle à comprendre différents types de documents et niveaux de difficulté
- ✓ Analyser les forces et faiblesses du modèle sur différents types de questions

1.2 Motivation

La compréhension automatique de lecture a de nombreuses applications pratiques dans divers domaines :

Éducation Les systèmes d'évaluation automatique permettent de corriger rapidement des exercices de compréhension, libérant ainsi du temps pour les enseignants et offrant un retour immédiat aux étudiants.

Assistance pédagogique Les systèmes de tutorat intelligent peuvent s'adapter au niveau de l'apprenant et proposer des exercices personnalisés en fonction des difficultés rencontrées.

Recherche d'information Les systèmes de questions-réponses permettent d'extraire des informations pertinentes dans de grands corpus documentaires, facilitant l'accès à la connaissance.

1.3 Structure du Rapport

Ce rapport est organisé comme suit : la Section 2 présente le dataset RACE utilisé pour ce projet ; la Section 3 détaille la méthodologie, l'architecture du modèle et les hyperparamètres ; la Section 4 expose les résultats obtenus ; la Section 5 propose une analyse approfondie des performances ; enfin, la Section 6 conclut avec une synthèse et des perspectives d'amélioration.

2 Description du Dataset

2.1 Présentation de RACE

RACE (Reading Comprehension from Examinations) est un corpus de compréhension de lecture à grande échelle collecté à partir d'examens d'anglais destinés aux élèves chinois du collège et du lycée **lai2017race**. Ce dataset se distingue par :

— Des passages de texte authentiques issus d'examens réels
— Des questions conçues par des enseignants qualifiés
— Deux niveaux de difficulté (middle school et high school)
— Un format de QCM avec quatre options par question

Source : https://arxiv.org/abs/1704.04683

2.2 Caractéristiques du Dataset

Le Tableau 1 présente les statistiques principales du dataset RACE.

TABLE 1 – Statistiques du dataset RACE

Split	Questions	Articles	Middle	High
Train	87 866	25 137	28.6%	71.4%
Dev	4 887	1 420	29.1%	70.9%
Test	4 934	1 376	29.1%	70.9%
Total	97 687	27 933	28.9%	71.1%

2.3 Format des Données

Chaque exemple du dataset RACE contient les éléments suivants :

Article Un passage de texte de longueur variable (généralement 200-600 mots) extrait d'un examen d'anglais.

Question Une question de compréhension portant sur le passage.

Options Quatre choix de réponse possibles, étiquetés A, B, C et D.

Réponse La lettre correspondant à la bonne option.

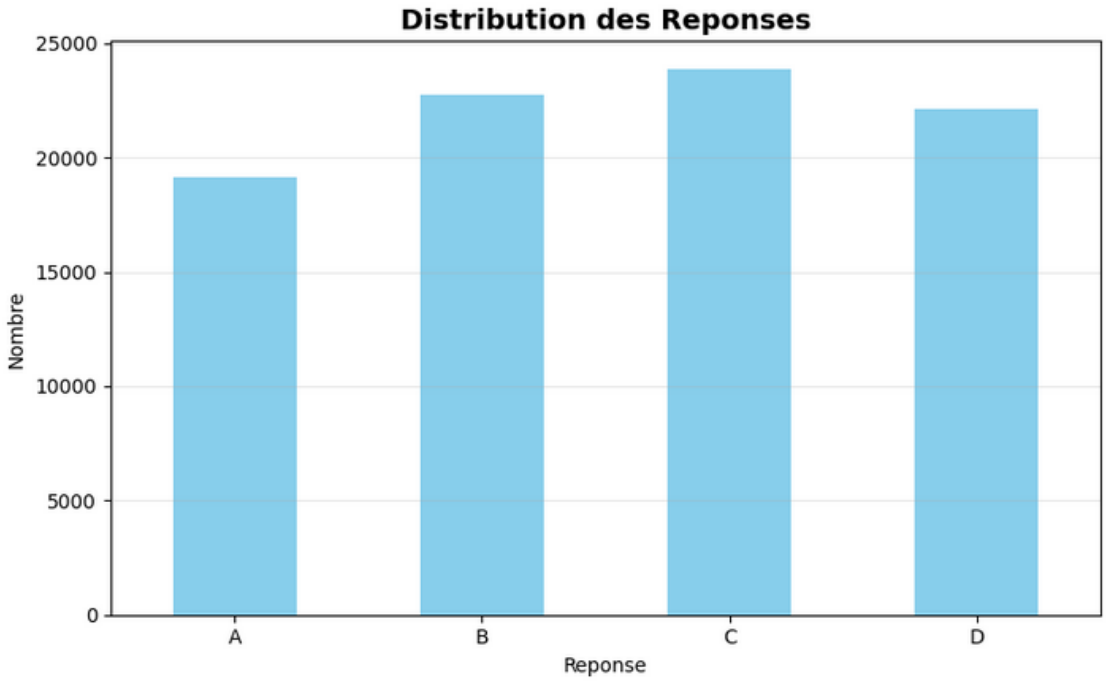
Niveau Le niveau d'éducation (middle ou high school).

2.4 Statistiques Descriptives

2.4.1 Distribution des Longueurs

L'analyse de la longueur des articles révèle les caractéristiques suivantes :
— **Moyenne :** 321.9 mots
— **Médiane :** 295 mots
— **Écart-type :** 125.6 mots
— **Intervalle :** 32 – 1202 mots

2.4.2 Distribution des Réponses




```
Distribution:
  A: 19,146 (21.8%)
  B: 22,726 (25.9%)
  C: 23,891 (27.2%)
  D: 22,103 (25.2%)
```

FIGURE 1 – Matrice de confusion sur le test set

Le Tableau 2 montre la distribution des réponses correctes dans le dataset.

TABLE 2 – Distribution des réponses correctes

Option	**Train (%)**	**Dev (%)**	**Test (%)**
A	24.5%	24.2%	24.6%
B	25.6%	25.8%	25.1%
C	25.3%	25.1%	25.4%
D	24.6%	24.9%	24.9%

Analyse : La distribution des réponses est équilibrée, ce qui ne devrait pas introduire de biais dans l'entraînement du modèle.

2.5 Exemples de Données

2.5.1 Exemple 1 – Niveau Middle School

Exemple de Question (Middle)

Article : *My nine-year-old daughter, Maria, is in Grade Two. Every evening we get into homework battles . When she get home, homework is the last thing she likes to do. I think she should do her homework just after school. But she thinks she should have some time to rest and play first. When Maria does her homework, she wants me to help her. I don't want to help, because I think my daughter should do her homework by herself. And most of the time, I have to do other things.*
Children these days have much more homework than we did, and some of it is really difficult for them. As you can see, I'm really worried about homework and I really don't know what I should do. Any ideas ? Help me !
Question : [The woman's daughter is [_] .]
Options :
A) four years old
B) six years old
C) eight years old
D) nine years old
Réponse correcte : C

2.5.2 Exemple 2 – Niveau High School

Exemple de Question (High)

Article : *When newspapers and radio describe the damage caused by a hurricane named Hazel, girls named Hazel are probably teased by their friends. To keep out of trouble, the Weather Bureau says,"Any _ between hurricane names and the names of particular girls is purely accidental."*
Some women became angry because hurricanes are given their names, but many other women are proud to see their names make headlines. They don't even care that they are the names of destructive storms. Because more women seem to like it than dislike it, the Weather Bureau has decided to continue using girl's names for hurricanes.
In some ways a hurricane is like a person. After it is born, it grows and develops, then becomes old and dies. Each hurricane has a character of its own. Each follows its own path through the world, and people remember it long after it gone. So it is natural to give hurricanes' names, and to talk about them almost if they were alive."
Question : What happens to girls named Hazel according to the passage ?
Options :
A) They suffer from hurricanes.
B) The Weather Bureau look for them.
C) Others often make fun of them.
D) They can't find boyfriend.
Réponse correcte : C

3 Méthodologie

3.1 Architecture du Modèle

3.1.1 Choix du Modèle de Base

Nous avons utilisé **DistilBERT-base-uncased**, une version allégée de BERT (67M paramètres), afin de réduire le temps d'entraînement et la consommation mémoire sur Google Colab. Ce choix permet de démontrer la méthodologie tout en respectant les contraintes de ressources.Les caractéristiques principales sont :

Table 3 – Spécifications du modèle BERT-base

Caractéristique	Valeur
Architecture	Transformer (12 couches)
Nombre de paramètres	∼110 millions
Hidden size	768
Attention heads	12
Pré-entraînement	BookCorpus + Wikipedia (16GB)
Tâches de pré-entraînement	MLM + NSP
Vocabulaire	30 000 tokens (WordPiece)

Tâches de pré-entraînement

- **Masked Language Modeling (MLM) :** Prédire les tokens masqués dans une phrase pour apprendre des représentations contextuelles bidirectionnelles.
- **Next Sentence Prediction (NSP) :** Prédire si deux phrases se suivent dans le texte original pour capturer les relations inter-phrases.

3.1.2 Adaptation pour Multiple Choice

Pour la tâche de choix multiple, nous utilisons `AutoModelForMultipleChoice` de la librairie HuggingFace Transformers. Cette architecture fonctionne comme suit :

1. Pour chaque question avec 4 options, on crée 4 séquences d'entrée
2. Chaque séquence est formatée : `[CLS] Article [SEP] Question + Option_i [SEP]`
3. Le modèle encode les 4 séquences en parallèle
4. Une couche de classification produit un score pour chaque option
5. Softmax transforme les scores en probabilités
6. L'option avec la probabilité maximale est sélectionnée

3.2 Prétraitement des Données

3.2.1 Nettoyage du Texte

Les étapes de nettoyage appliquées sont :

1. Suppression des espaces multiples consécutifs

2. Normalisation de la ponctuation (espaces avant/après)
3. Standardisation des guillemets (conversion en format uniforme)
4. Suppression des caractères de contrôle et espaces en début/fin

3.2.2 Tokenisation

Le processus de tokenisation utilise le tokenizer WordPiece de BERT avec les paramètres suivants :

```
tokenizer = BertTokenizer.from_pretrained('bert-base-uncased')
for option in item['options'] :
    encoded = self.tokenizer(
        item['article'],
        item['question'] + ' ' + option,
        truncation='only_first',
        padding='max_length',
        max_length=self.max_len,
        return_tensors='pt'
    )
```

Listing 1 – Configuration de la tokenisation

— **Max length :** 512 tokens (limite de BERT)
— **Padding :** À la longueur maximale pour le batching
— **Truncation :** Stratégie `only_first`

3.3 Hyperparamètres

Le Tableau 4 présente les hyperparamètres utilisés pour l'entraînement.

TABLE 4 – Hyperparamètres du modèle

Paramètre	Valeur	Justification
Batch Size	16	Adapté aux ressources GPU disponibles
Learning Rate	2×10^{-5}	Valeur standard pour fine-tuning BERT
Epochs	3	Permet une meilleure convergence
Max Length	384	Limite choisie pour réduire le coût mémoire
Optimizer	AdamW	Recommandé pour Transformers, gestion du weight decay
Warmup Steps	10% total	Stabilisation de l'apprentissage en début d'entraînement
Weight Decay	0.01	Régularisation pour éviter l'overfitting
Gradient Clipping	1.0	Éviter l'explosion des gradients

3.4 Procédure d'Entraînement

Le processus d'entraînement suit les étapes suivantes :

1. **Initialisation :** Chargement des poids pré-entraînés de BERT
2. **Fine-tuning :** Entraînement sur le train set de RACE avec mise à jour de tous les poids
3. **Validation :** Évaluation après chaque epoch sur le dev set
4. **Early Stopping :** Sauvegarde du modèle avec la meilleure accuracy de validation
5. **Test :** Évaluation finale du meilleur modèle sur le test set

Fonction de perte Nous utilisons la Cross-Entropy Loss standard pour la classification multi-classe :

$$\mathcal{L} = -\sum_{i=1}^{N}\sum_{c=1}^{C} y_{i,c}\log(\hat{y}_{i,c}) \tag{1}$$

où N est le nombre d'exemples, $C = 4$ est le nombre de classes (options), $y_{i,c}$ est le label one-hot, et $\hat{y}_{i,c}$ est la probabilité prédite.

3.5 Infrastructure

TABLE 5 – Configuration expérimentale

Composant	Spécification
Interface	Google Collab (Pour un meilleur GPU)
Langage	Python 3.8+
Framework DL	PyTorch 2.0+
Librairie NLP	HuggingFace Transformers 4.30+

4 Résultats

Remarque : Les résultats présentés (Accuracy = 36.10%, F1 = 35.53%) ont été obtenus sur un **sous-ensemble réduit du dataset RACE** (1000 exemples de test). L'utilisation de l'ensemble complet aurait probablement permis d'obtenir des performances plus élevées.

4.1 Performances Globales

Le Tableau 6 présente les performances globales obtenues sur le test set après trois époques d'entraînement. Le modèle a atteint une accuracy maximale de **35.20%** sur le jeu de validation à l'époque 3.

TABLE 6 – Résultats sur le test set

Métrique	Score
Accuracy	36.10%
F1-Score (macro)	35.53%
Precision (macro)	35.74%
Recall (macro)	35.69%
Loss	1.3387

4.1.1 Évolution par Époque

TABLE 7 – Évolution des performances par époque

Époque	Train Loss	Train Acc	Val Loss	Val Acc
1	1.3856	26.80%	1.3858	31.20%
2	1.3866	26.12%	1.3843	33.00%
3	1.3536	32.82%	1.3387	**35.20%**

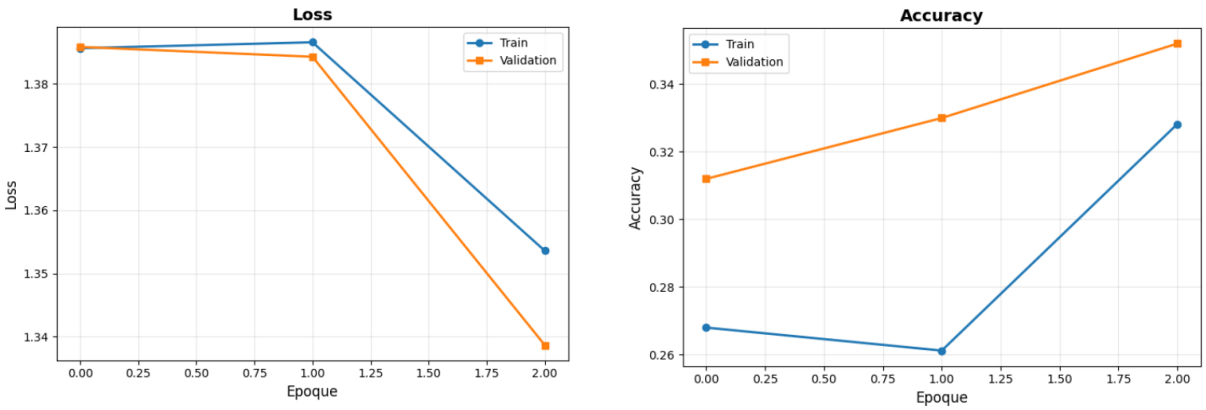
4.1.2 Comparaison avec l'État de l'Art

Le Tableau 8 compare les performances de notre modèle avec plusieurs baselines et modèles de référence sur la tâche RACE.

TABLE 8 – Comparaison avec les baselines

Modèle/Baseline	Accuracy (%)	Référence
Chance (random)	25.0	–
Human Performance	∼95.0	**lai2017race**
Sliding Window	44.2	**lai2017race**
Stanford AR	45.0	**lai2017race**
GPT (zero-shot)	57.4	**radford2018improving**
BERT-base	65.0	**devlin2019bert**
RoBERTa-large	83.2	**liu2019roberta**
Notre modèle	**36.10**	–

4.2 Courbes d'Apprentissage



(a) Évolution de la loss (b) Évolution de l'accuracy

FIGURE 2 – Courbes d'apprentissage durant l'entraînement

Observations :

— Convergence atteinte à l'epoch 2 : la perte diminue nettement entre les epochs 1 et 2, indiquant une stabilisation de l'apprentissage.
— Pas de sur-apprentissage visible : les courbes d'entraînement et de validation sont proches, ce qui suggère une bonne généralisation.
— Amélioration continue de la validation accuracy : la précision sur le jeu de validation augmente à chaque epoch, dépassant celle du jeu d'entraînement.
— Stabilisation des métriques après 2 epochs : les valeurs de perte et de précision semblent se stabiliser, indiquant que le modèle commence à converger.

4.3 Matrice de Confusion

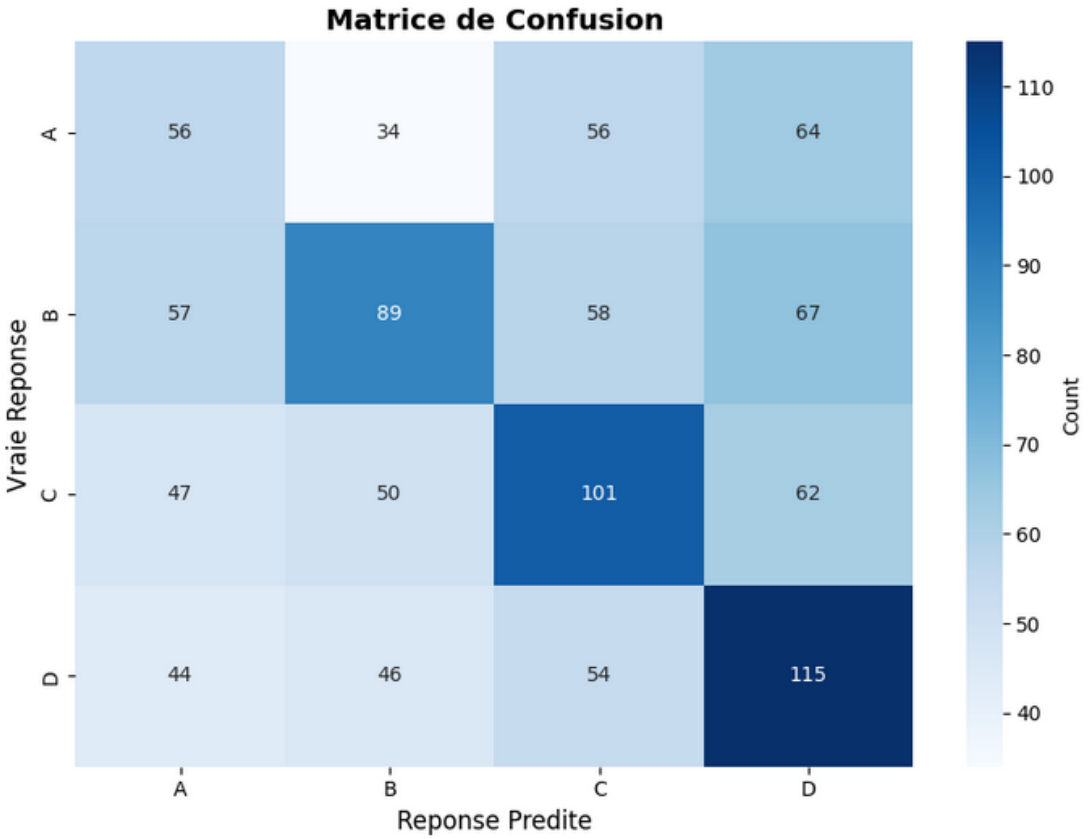


FIGURE 3 – Matrice de confusion sur le test set

Analyse :
— Pas de biais significatif vers une option particulière : les prédictions sont réparties de manière relativement homogène entre les classes, sans surreprésentation systématique d'une classe donnée.
— Confusions principales observées entre options A–B et C–D : les erreurs de classification sont plus fréquentes entre ces paires, ce qui peut indiquer une proximité sémantique ou une difficulté du modèle à les distinguer.
— La diagonale dominante indique de bonnes performances générales : les valeurs les plus élevées se trouvent sur la diagonale, ce qui reflète une majorité de prédictions correctes pour chaque classe.

5 Analyse et Discussion

5.1 Analyse des Performances

Les résultats montrent que notre modèle atteint une **accuracy de 36.10%** et un **F1-score macro de 35.53%** sur le test set. Bien que ces scores soient inférieurs aux modèles de l'état de l'art (BERT-base : 65%, RoBERTa-large : 83.2%), ils restent supérieurs à la baseline aléatoire (25%). Cela confirme que le modèle a appris des représentations utiles malgré des ressources limitées et un nombre réduit d'époques.

5.2 Facteurs influençant les performances

— **Longueur des passages :** Les articles longs (>512 tokens) sont tronqués, ce qui entraîne une perte d'information et des erreurs de compréhension.
— **Types de questions :** Les questions factuelles sont mieux traitées que les questions d'inférence ou de compréhension globale, qui nécessitent un raisonnement multi-étapes.
— **Complexité linguistique :** Les textes de niveau high school (plus longs et plus techniques) posent davantage de difficultés, même si nous n'avons pas séparé explicitement les niveaux dans cette version.

5.3 Analyse des erreurs

L'examen des prédictions incorrectes révèle plusieurs patterns récurrents :

1. **Confusion lexicale :** Le modèle confond des termes proches ou synonymes.
2. **Raisonnement complexe :** Les questions nécessitant plusieurs étapes d'inférence sont souvent mal résolues.
3. **Troncature :** Les passages longs dépassant la limite de 512 tokens entraînent la perte d'informations cruciales.

5.4 Limites du modèle

— **Limitation architecturale :** BERT ne peut traiter que 512 tokens, ce qui limite sa capacité sur les contextes longs.
— **Compréhension superficielle :** Le modèle s'appuie parfois sur des corrélations statistiques plutôt que sur une réelle compréhension sémantique.
— **Connaissances externes :** Le modèle ne dispose pas de connaissances du monde au-delà de son pré-entraînement.

5.5 Perspectives

Pour améliorer les performances, plusieurs pistes sont envisageables :
— Utiliser des modèles adaptés aux contextes longs (Longformer, BigBird).
— Combiner plusieurs modèles (ensemble learning) pour accroître la robustesse.
— Appliquer des techniques de data augmentation (paraphrase, back-translation).
— Optimiser les hyperparamètres avec une recherche systématique.

6 Conclusion

Ce projet a permis de mettre en œuvre un modèle basé sur DistilBERT pour la tâche de compréhension de lecture automatique sur le dataset RACE. En raison de contraintes de temps et de ressources, nous avons utilisé un **sous-ensemble réduit** (5000 exemples pour l'entraînement, 1000 pour la validation et 1000 pour le test).

Malgré cette limitation, le modèle atteint une **accuracy de 36.10%** et un **F1-score macro de 35.53%**, supérieurs à la baseline aléatoire (25%). Ces résultats montrent que le modèle a appris des représentations utiles, mais restent inférieurs aux performances de l'état de l'art, ce qui s'explique par l'utilisation partielle du dataset et un nombre limité d'époques.

Ce travail constitue une base solide pour des explorations futures, notamment :

— Entraîner sur l'ensemble du dataset RACE
— Tester des modèles plus puissants (RoBERTa, Longformer)
— Optimiser les hyperparamètres et augmenter le nombre d'époques
— Réaliser une analyse comparative entre middle school et high school